LAPORAN PROYEK

REKAYASA DATA



Anggota Kelompok B (Kelas A) :

Winata Cang Vielon	6162301007
Maria Chelsea Olivia	6162301009
Marco Dharmaputra	6162301041
Febriana Austin Darmawan	6162301069
Bryant Andrew Kristiali	6162301073

Dosen:
Robby, M.Si

PROGRAM STUDI MATEMATIKA
FAKULTAS SAINS
UNIVERSITAS KATOLIK PARAHYANGAN
2026

Daftar Isi

Daftar Isi **1**

Daftar Tabel **2**

Daftar Gambar **3**

1 Pendahuluan **4**

2 Eksplorasi Data **4**
2.1 Tabel Ojek Customers 4
2.2 Tabel Ojek Drivers 5
2.3 Tabel Ojek Orders 6
2.4 Tabel Ojek Payments 6

3 Proses pada MySQL **6**
3.1 Pembersihan Data 6
3.2 Validasi dan Pemeriksaan Konsistensi Data 7
3.3 Pembuatan Tabel Analisis 7
3.4 Analisis dan Deteksi Kecurangan 7

4 Proses pada Talend **10**
4.1 Tahap Ekstraksi 10
4.2 Tahap Transformasi 12
4.3 Tahap *Load* 14

5 Kesimpulan **16**

6 Lampiran **16**

Daftar Tabel

Tabel

1 Contoh format email tidak valid (tanpa @) pada *ojek_customers* 5
2 Contoh data *Missing Value* (Email Kosong) pada *ojek_customers* 5
3 Contoh format email tidak valid (tanpa @) pada *ojek_drivers* 5
4 Contoh data *Missing Value* (Email Kosong) pada *ojek_drivers* 5
5 Contoh anomali atribut *status* pada *ojek_drivers* 5
6 Contoh data *Missing Value* (ID Customer Kosong) pada *ojek_orders* 6
7 Contoh ketidaksesuaian nilai (*Discrepancy*) antara *ojek_orders* dan *ojek_payments* . . . 6
8 Beberapa baris hasil tabel jumlah perjalanan 8
9 Beberapa baris hasil tabel rata-rata jarak setiap pengemudi 8
10 Beberapa baris hasil tabel rata-rata jarak setiap pengemudi 8
11 Beberapa baris tabel view_driver_activity 8
12 Beberapa baris tabel view_driver_distance 9
13 Beberapa baris tabel view_driver_income 9
14 Beberapa baris tabel view_driver_fraud 9
15 driver_activity_B.csv 14
16 Data Jarak Tempuh Pengemudi 14
17 driver_income_b 15
18 fraud_detection_b 15

Daftar Gambar

Gambar

1 Penamaan Db Connection 10
2 Pengaturan pada DB Type 11
3 Pengaturan pada *retrieve schemas* 11
4 Pemilihan Dataset 12
5 Pembuatan Job 12
6 Design pada Beberapa Job 12
7 tMap pada driver_activity_job 13
8 tMap pada driver_distance_job 13
9 tMap pada driver_income_job 13
10 tMap pada fraud_detection_job 13
11 Automasi pada ojek_etl_job 14

1 Pendahuluan

Perkembangan teknologi informasi telah membawa perubahan besar pada industri transportasi, salah satunya melalui hadirnya layanan ojek online yang memungkinkan pelanggan terhubung dengan mitra pengemudi secara cepat dan praktis. PT MeongJek sebagai perusahaan penyedia layanan ojek online yang beroperasi di berbagai kota terus berupaya menjaga kualitas layanan, meningkatkan efisiensi operasional, serta memastikan transparansi transaksi bagi seluruh pengguna. Seiring meningkatnya jumlah pengguna dan transaksi setiap hari, data yang dihasilkan dari aktivitas operasional perusahaan juga semakin besar dan kompleks. Oleh karena itu, diperlukan pengelolaan data yang baik agar informasi yang tersedia dapat dimanfaatkan secara optimal dalam mendukung pengambilan keputusan berbasis data (*data-driven decision making*).

Dalam pengelolaan data operasional, perusahaan sering menghadapi berbagai permasalahan kualitas data. Data yang dikumpulkan dari sistem dapat mengandung nilai yang kosong (*missing values*), format penulisan yang tidak konsisten, maupun ketidaksesuaian hubungan antar data pada tabel yang berbeda. Selain itu, perusahaan juga perlu melakukan pemantauan terhadap performa mitra pengemudi dan mengidentifikasi potensi tindakan kecurangan (*fraud*). Salah satu bentuk kecurangan yang dapat terjadi adalah manipulasi perjalanan oleh pengemudi, misalnya dengan mengambil perjalanan berdurasi atau berjarak sangat pendek secara berulang untuk meningkatkan jumlah perjalanan dan memperoleh insentif tertentu.

Untuk mengatasi berbagai permasalahan tersebut, diperlukan data yang bersih, terstruktur, dan siap digunakan untuk analisis. Dalam proyek ini, peran *data engineer* berfokus pada perancangan dan implementasi proses ETL (*Extract, Transform, Load*) guna mengolah data mentah menjadi data yang berkualitas. Tahapan yang dilakukan meliputi eksplorasi data, pembersihan dan validasi data menggunakan kueri pada basis data MySQL, serta otomatisasi proses pengolahan data menggunakan *Talend Open Studio*. Hasil dari proses tersebut diharapkan mampu menghasilkan data yang akurat dan andal sehingga dapat digunakan untuk menjawab berbagai kebutuhan analisis bisnis, seperti mengidentifikasi pengemudi dengan jumlah perjalanan terbanyak, menghitung rata-rata jarak dan durasi perjalanan, menganalisis distribusi pendapatan pengemudi, serta mendeteksi indikasi fraud secara lebih efektif.

2 Eksplorasi Data

Diberikan empat buah file CSV mentah yang bernama ***ojek_drivers***, ***ojek_customers***, ***ojek_orders***, dan ***ojek_payments*** yang saling berkaitan mengenai operasional layanan ojek online pada PT MeongJek. Namun, setelah dilakukan peninjauan awal terhadap data, ditemukan bahwa struktur dan isi data pada masing-masing file masih belum sepenuhnya rapi, konsisten, maupun siap untuk langsung digunakan pada tahap pengolahan berikutnya, yaitu ETL (*Extract, Transform, Load*). Oleh karena itu, telah dilakukan eksplorasi terhadap keempat file mentah tersebut untuk mengidentifikasi berbagai bentuk ketidakkonsistenan dan anomali yang ada.

Hasil eksplorasi ini akan digunakan sebagai dasar dalam menentukan langkah-langkah pembersihan dan transformasi data agar data menjadi lebih terstruktur, konsisten, dan siap untuk dianalisis. Berikut hasil eksplorasi keempat data tersebut.

2.1 Tabel Ojek Customers

Pada data ini, ditemukan masalah berupa nilai kosong (*missing values*) serta ketidakkonsistenan pada format penulisan atribut email. Terdapat beberapa baris data yang tidak memiliki karakter penghubung (@) sehingga dikategorikan sebagai email tidak valid. Perhatikan contoh baris data pada tabel berikut.

Tabel 1: Contoh format email tidak valid (tanpa @) pada *ojek_customers*

id_customer	nama	email	Keterangan
14	Customer_14	cust14yahoo.com	Tidak Valid (Tanpa @)
28	Customer_28	cust28yahoo.com	Tidak Valid (Tanpa @)
56	Customer_56	cust56gmail.com	Tidak Valid (Tanpa @)

Selain itu, terdapat 8 baris data yang sama sekali tidak memiliki nilai (*null values*) pada kolom email. Perhatikan tabel berikut.

Tabel 2: Contoh data *Missing Value* (Email Kosong) pada *ojek_customers*

id_customer	nama	email	Keterangan
25	Customer_25	*NULL*	Missing Value (Email Kosong)
50	Customer_50	*NULL*	Missing Value (Email Kosong)
75	Customer_75	*NULL*	Missing Value (Email Kosong)

2.2 Tabel Ojek Drivers

Sama seperti tabel *customers*, atribut *email* pada tabel pengemudi juga memiliki kendala format yang tidak valid (tidak memiliki simbol @) pada 7 baris data, dan terdapat 6 baris data dengan nilai email yang kosong. Terdapat juga ketidakkonsistenan pada atribut status, nilai status operasional standar yaitu seperti '*Active*' dan '*Inactive*', terdapat variasi nilai berupa '*Unknown*' yang tidak memberikan kejelasan informasi mengenai status aktif dari mitra pengemudi tersebut.

Berikut adalah sampel data pengemudi yang memiliki alamat email dengan format tidak lengkap atau tidak valid karena tidak menyertakan karakter penghubung (@).

Tabel 3: Contoh format email tidak valid (tanpa @) pada *ojek_drivers*

id_driver	nama	email	Keterangan
10	Driver_10	driver10outlook.com	Tidak Valid (Tanpa @)
20	Driver_20	driver20gmail.com	Tidak Valid (Tanpa @)
40	Driver_40	driver40gmail.com	Tidak Valid (Tanpa @)

Berikut adalah sampel data pengemudi di mana informasi alamat email-nya kosong (*Missing Value*).

Tabel 4: Contoh data *Missing Value* (Email Kosong) pada *ojek_drivers*

id_driver	nama	email	Keterangan Anomali
15	Driver_15	*NULL*	Missing Value (Email Kosong)
30	Driver_30	*NULL*	Missing Value (Email Kosong)
45	Driver_45	*NULL*	Missing Value (Email Kosong)

Berikut adalah sampel data pengemudi yang mengalami ketidakkonsistenan nilai pada kolom status, di mana tercatat nilai berupa 'Unknown' yang mengakibatkan ketidakjelasan status operasional mitra.

Tabel 5: Contoh anomali atribut *status* pada *ojek_drivers*

id_driver	nama	status	Keterangan
18	Driver_18	Unknown	Status Tidak Terdefinisi
36	Driver_36	Unknown	Status Tidak Terdefinisi
54	Driver_54	Unknown	Status Tidak Terdefinisi

2.3 Tabel Ojek Orders

Pada tabel transaksi ini, ditemukan anomali berupa nilai kosong (*Missing Values*) yang cukup banyak pada atribut id_customer. Tercatat sebanyak 282 baris transaksi tidak mencantumkan identitas pelanggan. Kondisi ini menandakan bahwa beberapa pesanan ada yang tidak tercatat dan tidak terhubung ke akun pengguna secara spesifik. Masalah data anonim ini perlu diperbaiki agar tidak memicu eror relasi antar-tabel (*integrity constraint*) ketika proses impor ke basis data dilakukan. Perhatikan contoh data berikut.

Tabel 6: Contoh data *Missing Value* (ID Customer Kosong) pada *ojek_orders*

id_order	**id_driver**	**id_customer**	**tanggal**	**jarak_km**	**durasi**	**tarif**	**Keterangan**
17	1	*NULL*	2023-04-05	1.59	4	9600	ID Customer Kosong
24	1	*NULL*	2023-02-09	1.26	4	8400	ID Customer Kosong
45	1	*NULL*	2023-04-28	1.12	4	8500	ID Customer Kosong

2.4 Tabel Ojek Payments

Isi data dari tabel pembayaran ini secara struktur telah terisi penuh dan tidak memiliki nilai kosong (*Missing Values*) ataupun duplikasi baris. Namun, apabila disandingkan dengan tabel *ojek_orders*, ditemukan adanya ketidaksesuaian nilai (*Discrepancy*) antara atribut tarif pada tabel order dengan atribut amount (jumlah yang dibayarkan) pada tabel pembayaran untuk beberapa transaksi yang sama. Perhatikan tabel berikut.

Tabel 7: Contoh ketidaksesuaian nilai (*Discrepancy*) antara *ojek_orders* dan *ojek_payments*

id_order	**tarif** (*ojek_orders*)	**amount** (*ojek_payments*)	**Keterangan**
1	Rp8.200	Rp8.700	Pembayaran lebih mahal Rp500
3	Rp8.300	Rp8.600	Pembayaran lebih mahal Rp300
11	Rp9.200	Rp9.300	Pembayaran lebih mahal Rp100
14	Rp7.800	Rp8.000	Pembayaran lebih mahal Rp200
15	Rp10.700	Rp11.000	Pembayaran lebih mahal Rp300

3 Proses pada MySQL

3.1 Pembersihan Data

Tahap pertama yang dilakukan pada MySQL adalah proses pembersihan data untuk memperbaiki berbagai anomali yang ditemukan selama eksplorasi data. Pada tabel **ojek_customers** dan **ojek_drivers**, ditemukan alamat email yang tidak memiliki karakter "@" sehingga tidak memenuhi format email yang valid. Data tersebut diperbaiki dengan menambahkan karakter "@" pada posisi yang sesuai berdasarkan pola penulisan email yang digunakan.

Selain itu, terdapat beberapa data dengan nilai email kosong (*missing value*). Untuk menjaga konsistensi data dan menghindari nilai NULL pada atribut email, seluruh nilai kosong tersebut diisi dengan alamat email *placeholder* yang disesuaikan dengan ID masing-masing pengguna atau pengemudi. Format pengisian ini sekaligus disamaratakan menggunakan domain resmi perusahaan, yaitu menjadi (driver(id_driver)@meongjek.com) untuk tabel **ojek_drivers** dan (cust(id_customer)@meongjek.com) untuk tabel **ojek_customers**. Pada tabel **ojek_drivers** ditemukan nilai status berupa *Unknown* yang tidak sesuai dengan kategori status yang digunakan perusahaan. Oleh karena itu, seluruh nilai *Unknown* ditransformasikan menjadi *Inactive* agar atribut status hanya memiliki kategori yang jelas dan konsisten.

Selanjutnya, pada tabel **ojek_orders** ditemukan nilai kosong pada atribut **id_customer**. Meskipun atribut tersebut merupakan *foreign key* yang menghubungkan transaksi dengan pelanggan, data terkait tidak dihapus karena masih mengandung informasi transaksi yang relevan untuk analisis. Melalui proses pembersihan ini, seluruh data menjadi lebih konsisten dan siap digunakan pada tahap validasi serta analisis berikutnya.

3.2 Validasi dan Pemeriksaan Konsistensi Data

Setelah proses pembersihan selesai dilakukan, tahap berikutnya adalah melakukan validasi data untuk memastikan bahwa seluruh data yang tersimpan telah memenuhi aturan bisnis dan integritas basis data.

Validasi dilakukan dengan memeriksa kembali format email pada tabel **ojek_customers** dan **ojek_drivers** menggunakan pola pencarian yang memastikan seluruh alamat email telah mengandung karakter "@". Selain itu, dilakukan pemeriksaan terhadap nilai NULL pada setiap atribut penting untuk memastikan tidak terdapat lagi data yang kosong pada kolom-kolom yang bersifat wajib. Pemeriksaan juga dilakukan terhadap relasi antar tabel menggunakan operasi join antara tabel **ojek_orders**, **ojek_customers**, **ojek_drivers**, dan **ojek_payments**. Hasil pemeriksaan menunjukkan bahwa seluruh transaksi telah memiliki referensi pengemudi dan pelanggan yang valid sehingga tidak ditemukan pelanggaran *referential integrity*.

Tahap validasi ini penting untuk menjamin bahwa data yang digunakan pada proses analisis memiliki kualitas yang baik serta menghasilkan informasi yang akurat dan dapat dipercaya.

3.3 Pembuatan Tabel Analisis

Setelah data dinyatakan bersih dan valid, dilakukan pembuatan beberapa tabel hasil analisis menggunakan query agregasi. Tabel-tabel ini digunakan sebagai dasar dalam mengevaluasi performa pengemudi dan mendukung proses deteksi kecurangan.

Tabel pertama yang dibuat adalah tabel jumlah perjalanan pengemudi, yaitu hasil pengelompokan data berdasarkan **id_driver** dan **nama pengemudi** untuk menghitung total perjalanan yang telah diselesaikan oleh setiap pengemudi. Selanjutnya dibuat tabel rata-rata **jarak perjalanan pengemudi**, yaitu hasil perhitungan rata-rata nilai **jarak_km** pada setiap pengemudi. Nilai ini digunakan untuk mengidentifikasi pola perjalanan yang tidak wajar, seperti pengemudi yang melakukan banyak perjalanan dengan jarak yang sangat pendek.

Selain itu, dilakukan pula penggabungan hasil perhitungan jumlah perjalanan dan rata-rata jarak ke dalam satu tabel analisis yang berisi informasi performa setiap pengemudi. Tabel inilah yang kemudian digunakan sebagia dasar pada tahap deteksi *fraud*.

3.4 Analisis dan Deteksi Kecurangan

Pada tahap ini dilakukan analisis terhadap aktivitas perjalanan pengemudi untuk mendeteksi indikasi kecurangan. Analisis didasarkan pada jumlah perjalanan dan rata-rata jarak perjalanan yang ditempuh oleh setiap pengemudi. Pengemudi yang memiliki jumlah perjalanan tinggi namun rata-rata jarak perjalanan sangat rendah akan ditandai sebagai **FRAUD**, sedangkan pengemudi lainnya dikategorikan sebagai **NORMAL**.

Langkah pertama yang dilakukan adalah menghitung jumlah perjalanan setiap pengemudi. Proses ini diawali dengan melakukan *left join* tabel *ojek_drivers* dengan *ojek_orders* dan membuat kolom baru berdasarkan total banyaknya *id_order* sebagai jumlah perjalanan diurutkan dari yang terbanyak. Kolom ini dibuat dengan hasil pengelompokkan *nama* dan *id_driver*. Berikut beberapa baris hasilnya

Tabel 8: Beberapa baris hasil tabel jumlah perjalanan

id_driver	nama	jumlah_perjalanan
1	Driver_1	100
92	Driver_92	98
18	Driver_18	97

Selanjutnya, hitung rata-rata jarak perjalanan *(jarak_km)* untuk setiap pengemudi. Proses ini dilakukan dengan melakukan *left join* tabel *ojek_drivers* dengan *ojek_orders* dan membuat kolom baru dengan nama *rata_rata_jarak_km* dari hasil pembulatan rata-rata *jarak_km*. Kolom ini dibuat dengan hasil pengelompokkan *nama* dan *id_driver*. Berikut beberapa baris hasilnya.

Tabel 9: Beberapa baris hasil tabel rata-rata jarak setiap pengemudi

id_driver	nama	rata_rata_jarak_km
92	Driver_92	1.23
51	Driver_51	1.26
18	Driver_18	1.26

Melalui kedua tabel tersebut, dapat ditentukan pengemudi yang terdeteksi curang (**FRAUD**), yaitu pengemudi dengan rata-rata jarak perjalanan sangat kecil, di bawah 2 km, dan banyak perjalanan tinggi, melebihi 50 perjalanan. Tabel berikut ini menampilkan beberapa baris dari seluruh ID pengemudi beserta kategori masing-masing diantara **FRAUD** dan **NORMAL**.

Tabel 10: Beberapa baris hasil tabel rata-rata jarak setiap pengemudi

id_driver	nama	jumlah_perjalanan	rata_rata_jarak_km	status_fraud
1	Driver_1	100	1.3	FRAUD
2	Driver_2	34	5.22	NORMAL
3	Driver_3	23	5.38	NORMAL
4	Driver_4	31	6.59	NORMAL
5	Driver_5	69	5.5	NORMAL

Proses terakhir pada MySQL adalah membuat empat buah table view dengan nama

- view_driver_activity;
- view_driver_distance;
- view_driver_income;
- view_fraud_detection.

dengan tampilan masing-masing sebagai berikut.

Tabel 11: Beberapa baris tabel view_driver_activity

id_driver	nama	status	j_p	r_r_d_m	t_p	t_t
1	Driver_1	Inactive	100	4.13	2023-01-03	2023-12-30
92	Driver_92	Active	98	3.85	2023-01-16	2023-12-30
18	Driver_18	Inactive	97	3.92	2023-01-02	2023-12-26
51	Driver_51	Active	92	4.11	2023-01-01	2023-12-29
100	Driver_100	Inactive	86	4.06	2023-01-09	2023-12-23

dengan

- j_p sebagai jumlah_perjalanan

- r_r_d_m sebagai rata_rata_durasi_menit;
- t_p sebagai tanggal_pertama;
- t_t sebagai tanggal_terakhir.

Tabel 12: Beberapa baris tabel view_driver_distance

id_driver	nama	j_p	r_r_j	min_j	max_j	t_j
92	Driver_92	98	1.23	0.52	1.91	120.62
51	Driver_51	92	1.26	0.50	1.99	115.76
18	Driver_18	97	1.26	0.50	1.99	122.56
100	Driver_100	86	1.27	0.52	2.00	109.14
55	Driver_55	81	1.27	0.52	2.00	103.01

dengan

- j_p sebagai jumlah_perjalanan;
- r_r_j sebagai rata_rata_jarak_km;
- min_j sebagai min_jarak_km;
- max_j sebagai max_jarak_km;
- t_j sebagai total_jarak_km.

Tabel 13: Beberapa baris tabel view_driver_income

id_driver	nama	j_p	t_p	r_r_p	min_p	max_p
86	Driver_86	76	1748600	23007.89	8000	34500
10	Driver_10	77	1744100	22650.65	7800	35300
99	Driver_99	78	1680300	21542.31	7600	34500
57	Driver_57	76	1659900	21840.79	8200	34000
70	Driver_70	77	1645900	21375.32	8500	35200

dengan

- j_p sebagai jumlah_perjalanan;
- t_p sebagai total_pendapatan;
- r_r_p sebagai rata_rata_pendapatan;
- min_p sebagai min_pendapatan;
- max_p sebagai max_pendapatan.

Tabel 14: Beberapa baris tabel view_driver_fraud

id_driver	nama	j_p	r_r_j_km	r_r_d_m	t_p	s_f
1	Driver_1	100	1.3	4.13	890000	FRAUD
2	Driver_2	34	5.22	17.47	702100	NORMAL
3	Driver_3	23	5.38	18.96	482500	NORMAL
4	Driver_4	31	6.59	22.35	766200	NORMAL

Dilanjutkan ke halaman berikutnya

5	Driver_5	69	5.5	17.96	1480600	NORMAL

dengan

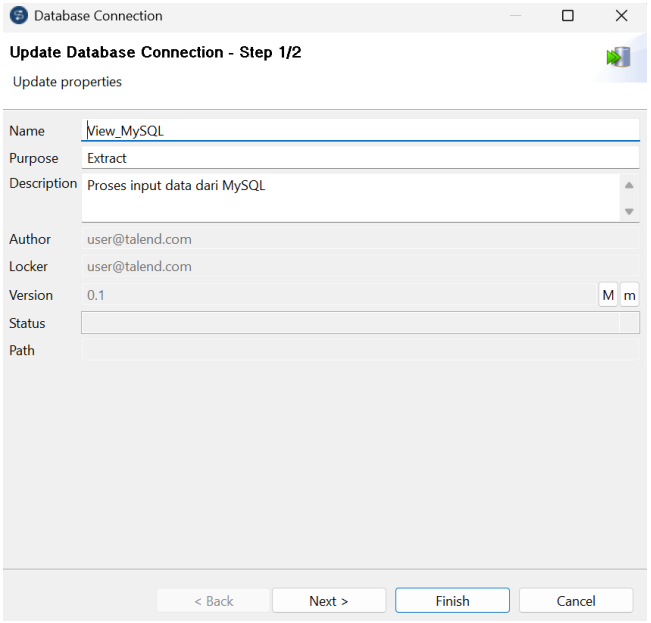
- j_p sebagai jumlah_perjalanan;
- r_r_j_km sebagai rata_rata_jarak_km;
- r_r_d_m sebagai rata_rata_durasi_menit;
- t_p sebagai total_pendapatan;
- s_f sebagai status_fraud.

4 Proses pada Talend

Setelah melakukan beberapa tahap pada ETL yang dapat dilakukan pada MYSQL untuk membuat tabel-tabel *view* yang diperlukan, tabel view tersebut akan dimasukkan ke dalam Talend untuk dilakukan ETL yang menghasilkan empat tabel berbentuk csv. Dalam Talend, dilakukan tahap yang kurang lebih serupa dengan yang dikerjakan pada MYSQL tapi akan dilakukan beberapa transformasi yang lebih mudah dilakukan.

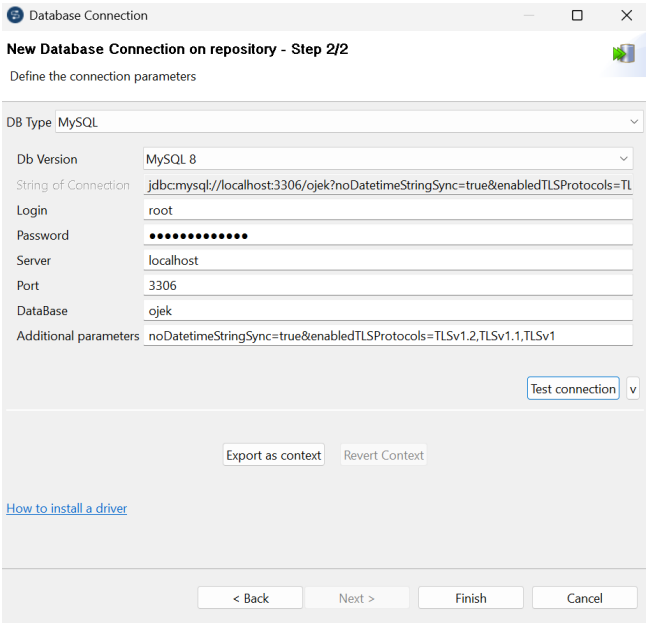
4.1 Tahap Ekstraksi

Sebelum memulai tahap ekstraksi, akan dibuat terlebih dahulu Db Connection pada metadata. Dapat dibentuk dengan setingan berikut



Gambar 1: Penamaan Db Connection

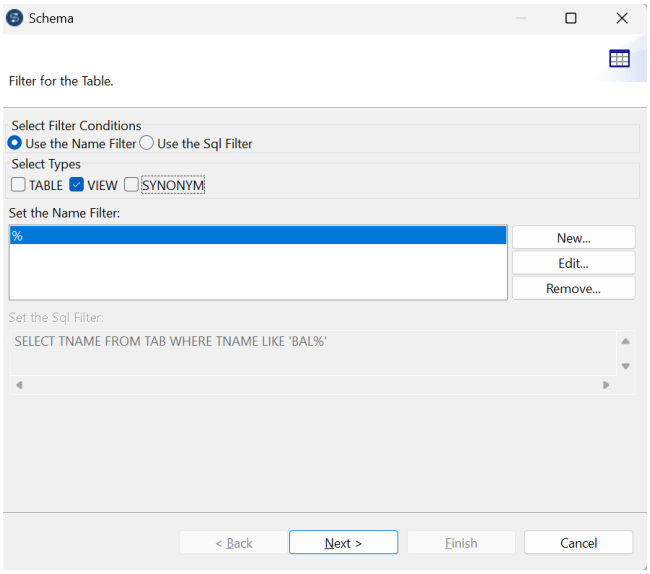
Setelah klik *next*, tentukan Db Typenya yaitu MySQL dan masukkan beberapa bagian sesuai dengan 2



Gambar 2: Pengaturan pada DB Type

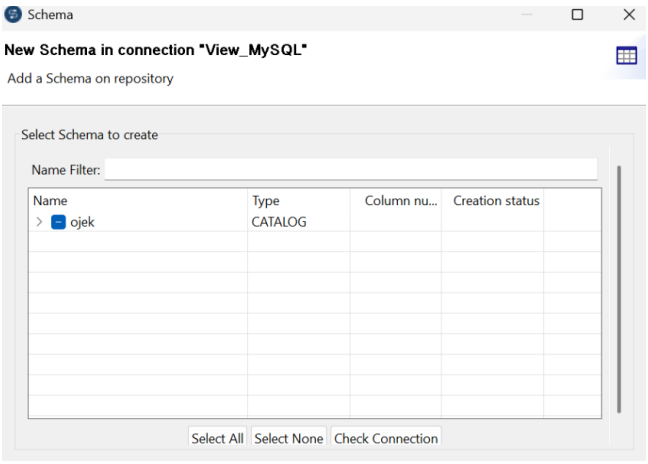
Lakukan *Test connection* terlebih dahulu untuk mengecek apakah pengaturan sudah benar atau belum. Lalu klik *Export as content* dan ikuti pengaturan standarnya. Dengan begitu, Db connection sudah siap digunakan.

Selanjutnya untuk memanggil tabel view ke talend, klik kanan pada Db connection yang telah dibuat dan pilih *retrieve schemas* dengan mengikuti setinggan seperti berikut



Gambar 3: Pengaturan pada *retrieve schemas*

Kemudian, centang dataset (ojek) lalu finish.

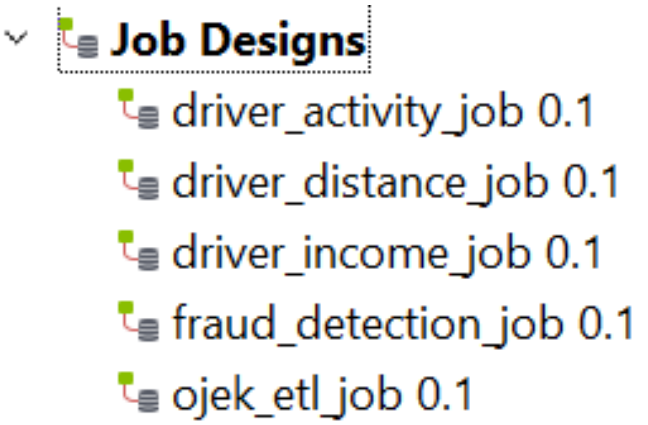


Gambar 4: Pemilihan Dataset

Tahap ekstraksi sudah selesai dan data siap untuk melakukan tahap selanjutnya.

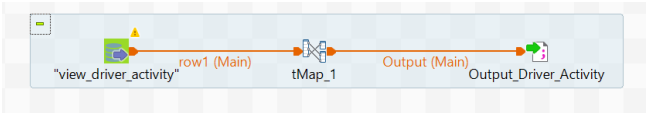
4.2 Tahap Transformasi

Sebelum melakukan tahap transformasi, dibentuk 5 job dengan penamaan masing-masing seperti berikut



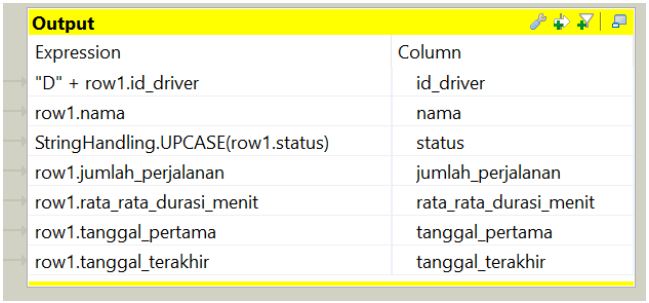
Gambar 5: Pembuatan Job

Pada job driver_activity_job, driver_distance_job, driver_income_job, dan fraud_detection_job, bentuk rangkaian seperti berikut



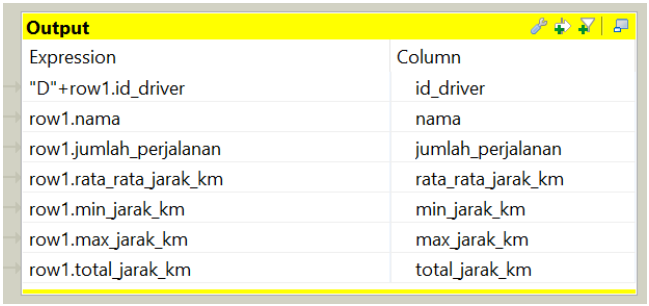
Gambar 6: Design pada Beberapa Job

Untuk driver_activity_job, tahap transformasi berupa pengubahan pada id driver dengan penambahan D disetiap angkanya dan mengubah setiap status dengan merubah menjadi huruf kapital semua yang dijelaskan dengan gambar berikut



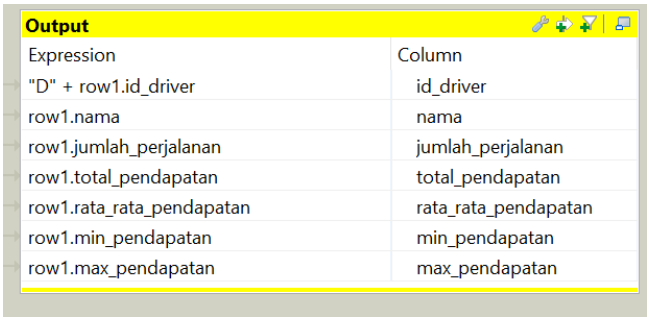
Gambar 7: tMap pada driver_activity_job

Untuk driver_distance_job, tahap transformasi berupa pengubahan pada id driver dengan penambahan D disetiap angkanya yang dijelaskan dengan gambar berikut



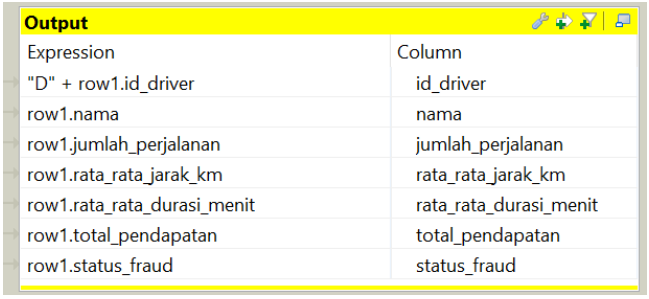
Gambar 8: tMap pada driver_distance_job

Untuk driver_income_job, tahap transformasi berupa pengubahan pada id driver dengan penambahan D disetiap angkanya yang dijelaskan dengan gambar berikut



Gambar 9: tMap pada driver_income_job

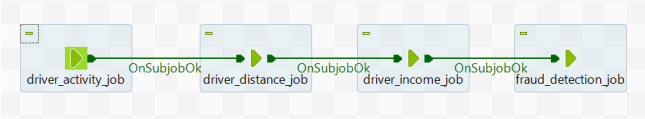
Untuk fraud_detection_job, tahap transformasi berupa pengubahan pada id driver dengan penambahan D disetiap angkanya yang dijelaskan dengan gambar berikut



Gambar 10: tMap pada fraud_detection_job

Pada job ojek_etl_job, dilakukan automasi berupa orkestra dengan menarik setiap job pada bagian

design seperti berikut



Gambar 11: Automasi pada ojek_etl_job

4.3 Tahap *Load*

Pada tahapan load, driver_activity job, driver_distance job, driver_income job, dan fraud_detection job sebelumnya sudah dibuat alur load dengan menggunakan tFileDelimetedOutput yang dijalankan secara bersamaan pada job ojek_etl_job. Berikut adalah 5 barisan teratas, beserta penjelasannya

1. **driver_activity_b**

Tabel 15: driver_activity_B.csv

id_driver	nama	status	jumlah_perjalanan	rata_rata_durasi	tanggal_pertama	tanggal_terakhir
D1	Driver_1	INACTIVE	100	4.13	2023-01-03	2023-12-30
D2	Driver_2	INACTIVE	34	17.47	2023-01-14	2023-12-15
D3	Driver_3	ACTIVE	23	18.96	2023-01-10	2023-12-27
D4	Driver_4	ACTIVE	31	22.35	2023-01-02	2023-12-27
D5	Driver_5	INACTIVE	69	17.96	2023-01-04	2023-12-31

- **id_driver**: Kode unik yang digunakan untuk mengidentifikasi setiap pengemudi.
- **nama**: Nama dari pengemudi yang bersangkutan.
- **status**: Menunjukkan status keaktifan pengemudi saat ini, apakah sedang `ACTIVE` atau `INACTIVE`.
- **jumlah_perjalanan**: Total keseluruhan pesanan atau perjalanan yang telah diselesaikan oleh pengemudi.
- **rata_rata_durasi**: Rata-rata waktu yang dihabiskan oleh pengemudi untuk menyelesaikan satu kali perjalanan (biasanya dalam menit).
- **tanggal_pertama**: Tanggal di mana pengemudi pertama kali mengambil perjalanan atau mulai tercatat dalam sistem pada periode data tersebut.
- **tanggal_terakhir**: Tanggal terakhir kali pengemudi mengambil perjalanan atau tercatat aktif beroperasi.

2. **driver_distance_b**

Tabel 16: Data Jarak Tempuh Pengemudi

id_driver	nama	jumlah_perjalanan	rata_rata_jarak_km	min_jarak_km	max_jarak_km	total_jarak_km
D1	Driver_1	100	1.30	0.53	1.98	130.00
D2	Driver_2	34	5.22	1.06	9.67	177.34
D3	Driver_3	23	5.38	1.24	9.72	123.74
D4	Driver_4	31	6.59	1.70	9.95	204.30
D5	Driver_5	69	5.50	1.36	9.96	379.26

- **id_driver**: Kode unik pengidentifikasi pengemudi.
- **nama**: Nama dari pengemudi yang bersangkutan.
- **jumlah_perjalanan**: Total keseluruhan perjalanan yang telah diselesaikan oleh pengemudi.

- **rata_rata_jarak_km**: Rata-rata jarak yang ditempuh pengemudi untuk setiap perjalanannya (dalam satuan kilometer).
- **min_jarak_km**: Jarak tempuh paling pendek (minimum) yang pernah dilakukan oleh pengemudi dalam satu kali perjalanan.
- **max_jarak_km**: Jarak tempuh paling jauh (maksimum) yang pernah diselesaikan oleh pengemudi dalam satu kali perjalanan.
- **total_jarak_km**: Akumulasi atau total keseluruhan jarak tempuh dari seluruh perjalanan yang diselesaikan oleh pengemudi.

3. **driver_income_b**

Tabel 17: driver_income_b

id_driver	nama	jumlah_perjalanan	total_pendapatan	rata_rata_pendapatan	min_pendapatan	max_pendapatan
D1	Driver_1	100	890000	8900.00	6100	11200
D2	Driver_2	34	702100	20650.00	8200	34400
D3	Driver_3	23	482500	20978.30	8300	33900
D4	Driver_4	31	766200	24716.10	9900	34900
D5	Driver_5	69	1480600	21458.00	8600	35200

- **id_driver**: Kode unik pengidentifikasi pengemudi.
- **nama**: Nama dari pengemudi yang bersangkutan.
- **jumlah_perjalanan**: Total keseluruhan perjalanan yang telah diselesaikan oleh pengemudi.
- **total_pendapatan**: Jumlah keseluruhan uang (pendapatan kotor) yang berhasil dikumpulkan pengemudi dari semua perjalanannya.
- **rata_rata_pendapatan**: Nilai rata-rata uang yang didapatkan pengemudi dari setiap satu kali perjalanan.
- **min_pendapatan**: Nilai pendapatan paling kecil (minimum) yang pernah didapatkan dari satu kali perjalanan.
- **max_pendapatan**: Nilai pendapatan paling besar (maksimum) yang pernah didapatkan dari satu kali perjalanan.

4. **fraud_detection_b**

Tabel 18: fraud_detection_b

id_driver	nama	jumlah_perjalanan	rata-rata_jarak_km	rata_rata_durasi_menit	total_pendapatan	status_fraud
D1	Driver_1	100	1.30	4.13	890000	FRAUD
D2	Driver_2	34	5.22	17.47	702100	NORMAL
D3	Driver_3	23	5.38	18.96	482500	NORMAL
D4	Driver_4	31	6.59	22.35	766200	NORMAL
D5	Driver_5	69	5.50	17.96	1480600	NORMAL

- **id_driver**: Kode unik pengidentifikasi pengemudi.
- **nama**: Nama dari pengemudi yang bersangkutan.
- **jumlah_perjalanan**: Total keseluruhan pesanan atau perjalanan yang telah diselesaikan oleh pengemudi.
- **rata-rata_jarak_km**: Rata-rata jarak yang ditempuh pengemudi untuk setiap perjalanannya (dalam kilometer).

- **rata_rata_durasi_menit**: Rata-rata waktu yang dihabiskan untuk menyelesaikan satu kali perjalanan (dalam menit).
- **total_pendapatan**: Jumlah keseluruhan pendapatan yang dikumpulkan dari semua perjalanan.
- **status_fraud**: Label akhir yang menunjukkan apakah perilaku dan transaksi pengemudi terindikasi melakukan kecurangan (`FRAUD`) atau beroperasi secara wajar (`NORMAL`).

5 Kesimpulan

Laporan proyek ini menguraikan penerapan proses Extract, Transform, Load (ETL) untuk mengatasi masalah kualitas data operasional pada layanan ojek online PT Meong Jek. Tahap awal eksplorasi menemukan berbagai anomali pada data mentah, seperti format email yang tidak valid, nilai kosong pada ID pelanggan, serta ketidakkonsistenan status pengemudi. Pembersihan dan validasi data kemudian dilakukan secara langsung pada basis data MySQL, di mana alamat email distandardisasi menggunakan domain resmi perusahaan, status yang tidak jelas diubah menjadi "Inactive", dan transaksi tanpa identitas pelanggan dihapus demi menjaga integritas relasi antar-tabel.
Setelah data terstruktur dengan bersih, tahap selanjutnya berfokus pada analisis performa pengemudi dan deteksi indikasi kecurangan (fraud). Pengemudi yang memiliki jumlah penyelesaian perjalanan tinggi (lebih dari 50 perjalanan) dengan rata-rata jarak yang sangat pendek (di bawah 2 km) akan ditandai dengan status "FRAUD", sedangkan yang lainnya dikategorikan "NORMAL". Alur kerja pengolahan ini kemudian diotomatisasi lebih lanjut menggunakan Talend Open Studio untuk melakukan transformasi akhir, seperti modifikasi pada ID pengemudi, sebelum datanya diekstrak ke dalam empat file CSV yang akurat dan siap digunakan untuk pengambilan keputusan bisnis.

6 Lampiran

Berikut adalah lampiran link Google Docs yang berisi prompt AI yang kami gunakan:
https://docs.google.com/document/d/1KjdM72pYNey5eLNye8MrZKslZ_46_ThQ4NbLAYtvqbA/edit?usp=sharing

Berikut adalah lampiran link Github:
https://github.com/brydrw27/UASREKAYASADATAC-B